DeepL
订阅DeepL Pro以翻译大型文件。
欲了解更多信息，请访问www.DeepL.com/pro。

Pang、Lee 和 Vaithyanathan [PLV02]，只有正负
使用的评级。
低于三星的评分负面评分，高于三星的评分被视为正面评分；所有三星评分均被删除。为了中性训练示例的空白，我们使用了*莱比锡*语料库中的文本。该数据集由抓取的新闻文本和维基百科文章组成。

PotTS [Sid16] 包含来自社交媒体平台 Twitter 的 7504 篇文本。这些文本收集于 2013 年，由两位专家手动标注。作者使用关键词过滤器选择了以下主题的推文：2013 年德国联邦议院选举、2013 年教皇选举、一般政治话题讨论和日常对话。

SB1 0k [Cie+17] 包含 9,783 条贴标签的德语推文。每条推文由 3 名注释者分配到五个类别之一：正面、负面、中性、混合和未知。不过，作者并未公布推文的全文，而是公布了注释推文的 ID。在下载数据时（2018 年），相当一部分推文已无法访问。因此，我们使用了以前收集的数据集版本 (13)，其中包含 7,474 条全文推文。实验中只使用正面、负面和中性类别。

GermEval-2017 [Woj+17] 是 GermEval-2017 基于方面的情感分析共享任务的一部分。该数据集由来自社交媒体、微博、新闻和问答网站的有关德国铁路的文档组成。该数据集总共包含近 28,000 篇文档，其中 23,525 篇文档可供公众使用。文本收集时间为 2015 年 5 月至 2016 年 6 月。

应用程序评论情感语料库 Scare [Sän+16]，包含来自 Google Play 商店的 800,000 多条评论。该语料库包含 11 个类别 148 个应用程序的评论（详细列表可在语料库网站上[14]）。作者发现，这些评论比典型的产品评论更短，而且使用口语化语言和更灵活的语法。所有评论的检索时间为 2014 年 12 月至 2015 年 6 月。

Filmstarts 数据集由 71,229 篇用户用德语撰写的电影评论组成。该数据集由德

国网站filmstarts.de使用网络爬虫收集。用户可以给出 0.5 星至 5 星的评分。该数据集中有 40,049 份文件，正面评价占大多数，只有 15,61 0 个评价归类为负面评价。整个数据集于 2018 年 10 月 15 日至 16 日下载，包含截至该日期的评分。

'(3)https://github.com/WIadimirSidorenko/CGSA
'(4)http://www.romanklinger.de/scare

holidaycheck 数据集由德国网站 *holidaycheck.de* 上的酒店评论组成。该网站的用户可以撰写一般性评论并对其酒店进行评分。此外，他们还可以对六个具体方面进行评分：位置与环境、客房、服务、餐饮、运动与娱乐以及酒店。因此，一份完整的评论包含七个文本和相应的星级，从零星到六星不等。共下载了以下十个目的地酒店的 4,832,001 对文字评价：埃及、保加利亚、中国、希腊、印度、马略卡岛、墨西哥、特内里费岛、泰国和突尼斯。评论下载时间为 2018 年 11 月至 12 月，包括截至该日期的评论。删除所有无星评论和四星评论后，数据集包含 3524193 对文本评论。

leipzig-wikipedia是从[GEQ12]发布的语料库中提取的。该数据集用于缩小中性文本的差距。该数据集包含维基百科中以中性语气书写的句子，因此不包含任何情感。该数据集由 1,000,000 篇文档组成，在这项工作中，这些文档被标记为中性。使用的是 2016 年版本。

情绪数据集包含在服务机器人 "绿野仙踪 "实验中记录的语句列表。我们注意到，用户在与机器人交谈时也使用了侮辱性词语。由于这些词语大多会在社交媒体和评论平台上被过滤，因此其他数据集并不包含此类词语。作为一种数据增强技术，同义词替换被用来根据录音生成新的语句。除负面反馈外，该数据集还包含正面反馈以及有关性身份和性取向的声明，这些声明被标记为中性。该数据集总共包含 1,306 个文本。

每个源数据集都经过预处理、分 类，然后重新组合。预处理包括以下步骤：删除所有以 @ 符号开头的 URL 和用户名，并用数字词替换所有数字。此外，还删除了所有非德语字符和标点符号。笑脸和表情符号已被情感标签取代。这种替换使用了 [Sän+16] 提供的作为语料库一部分的词典。预处理后不包含任何字符的文本被删除。表 6.9 显示了预处理后每个数据集每类文本的数量。
70% 的数据用于训练模型，20% 的数据用于在验证集上优化超参数，

10% 的数据用于测试数据集，以比较不同的模型。为了保持三个类别的不同比例，每个类别都采用了这种三分法。

我们创建了两个版本的数据集，一个是包含全部 535.5 万条文本的非平衡数据集，另一个是包含 183.4 万条文本的平衡数据集。平衡数据集是通过下采样和

每类包含 611 267 个样本。

6.4.2 模式

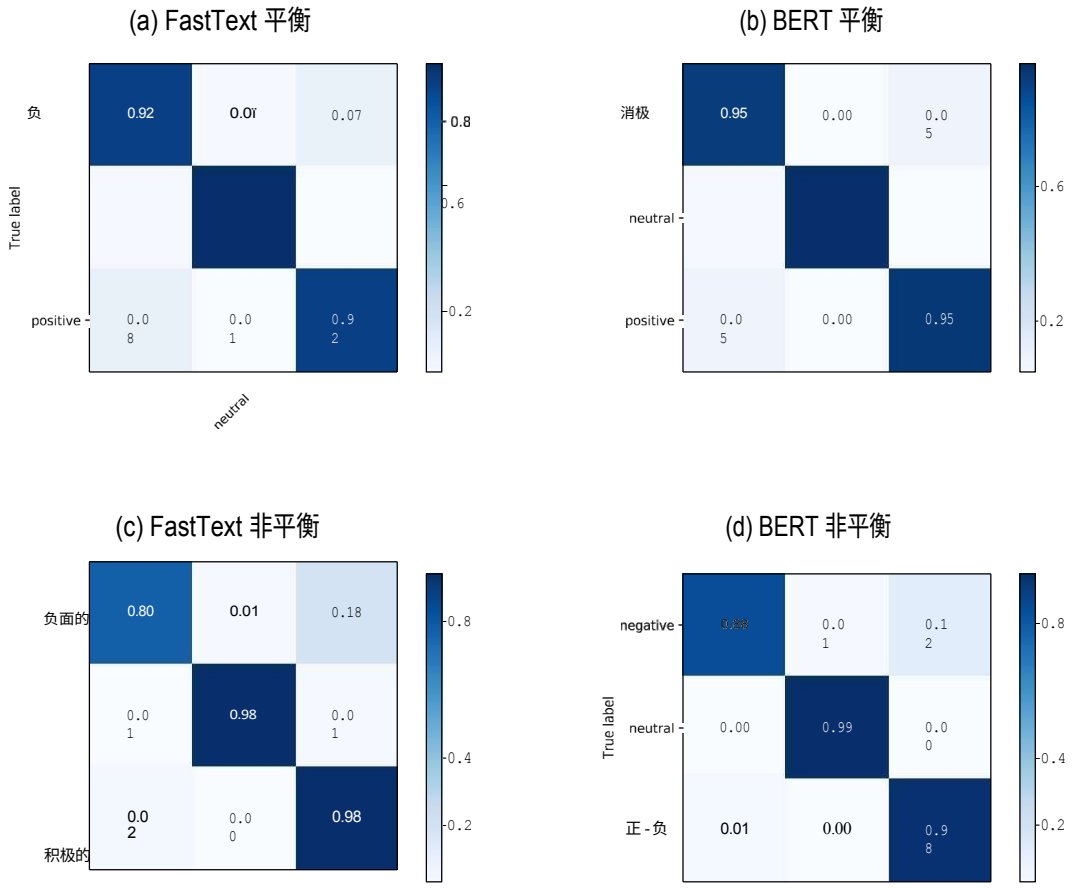

图 6.5：四个混淆矩阵，用于比较 FastText 和 BERT 对平衡和不平衡数据集的分类结果。对于这两种模型，当使用不平衡数据集进行训练时，负类的准确率都会下降。所有数值均四舍五入。

我们选择了两种不同的机器学习方法来训练情感分类模型。我们使用 F/",值和混淆矩阵了 FastText 和 BERT 的性能。此外，我们还在平衡和不平衡版本的数据集上对这两种模型进行了训练，以测试模型是否倾向于使用更多的训练样本进行分类。为了比较模型在每个源数据集上的性能，测试数据集中的每个样本

都保留了源数据集的平均值。这样就可以计算出每个源数据集的 1 值。由于 1 值用于二元分类任务，因此使用了 [Seb02, 第 33 页] 中定义的微观和宏观平均 +1 值。微观/宏观
值是所有三个等级 +1 值的加权平均值。 " " 值为
每个等级的平均值。

快速文本

FastText 对基于词的嵌入的改进。它基于一组 n-grams 而不是一组单词[Boj+17]。这使得 FastText 可以处理词汇之外的单词，这在处理德语复合词和转折词时是一个重要优势。

FastText 注重计算效率是选择该模型的另一个原因。作者指出，该模型的结果与基于 LSTM 和 RNN 的模型处于同一水平，但计算速度快了一个数量级。由于现有移动机器人的计算和能源资源有限，因此在机器人应用中应考虑到这一点。因此，FastText 被选为比较模型。然而，FastText 的一个重要缺点是它对上下文不敏感。在该模型中，每个单词都由相同的向量表示，与单词的上下文无关。

为了训练 FastText 模型，首先在 540 万文本上训练了跳格词向量。对模型进行了 20 次历时，学习率为 0.1，并使用大词和预训练词向量。

跳格[Mik+13]是一种建模方法，它通过使用目标词来预测给定窗口中的周围上下文词，从而学习文本中词的概率分布。用这种方法训练的模型可用于生成跳格词向量。这些向量表示单词，上下文相似的单词会相互靠近从而捕捉语义和句法上的单词相似性。

表 6.1 0：在平衡和非平衡数据集上训练的 FastText 的 1 微米值。

数据集	平衡	不平衡
惊吓	0.9071	0.9083
GermEval-2017	0.6970	0.6980
假日检查	0.9296	0.9639
SB10k	0.6862	0.6213
电影发行	0.8206	0.8432
PotTS	0.5268	0.54J 6
情感	0.9913	0.9773
莱比锡-维基百科	0.9883	0.9886
复式	0.9405	0.9573

表 6.1 0 显示了平衡数据集和不平衡数据集的 +1m/cro 值。非平衡数据集的 +1m'cro综合值 0.9573 至 0.9405 较高。

同时还计算了宏观 F/ 值，平衡数据集为 0.9406，不平衡数据集为 0.9268。微观和宏观 F/ 值之间的差异表明，在不平衡数据集上训练的模型偏向于样本多的类别。图 6.5a 和 6.5c 中两个数据集模型的混淆矩阵比较显示，负类的准确率从 0.92 降至 0.80。这 1 2 % 的负样本主要是

则被标记为阳性。因此，下文将使用在平衡数据集上训练的 FastText 模型。

BERT

BERT 是一种能够根据上下文处理单词的模型。该模型采用双向、基于变压器的编码器网络结构 [+J 7]。BERT 的作者发布了两种不同规模的预训练模型：*BERT base*（由 12 个变压器编码器层组成）和 *BERT large*（由 24 个变压器编码器层组成）。

我们使用了 Transfomers 库[15] 的 BERT 实现，该实现在 [Wol+19] 中有所描述。该平台还提供德国 BERT 基本模型。

情感分类任务中，BERT 模型的结果将在前馈层的帮助下进行分类。BERT 变换层的权重取自预训练模型，并与前馈层一起训练。

根据文献[Dev+19c]的建议，所有 BERT 模型采用 2 10- 的学习率、32 的批量大小和 256 的最大标记长度进行训练，共训练了三个历元。

表 6.11 显示，在不平衡数据集上训练的 BERT 模型比在平衡数据集上训练的模型性能高出 +1.08 F/-score。与 FastText 模型一样，在不平衡集上训练的 BERT 模型也偏向于正分类。图 6.5b 和 6.5d 显示，负类的准确率从 0.95 降至 0.88，被分类为正类的负样本数量从 5%12%。因此，我们建议在平衡数据集上 BERT 模型。总体而言，在平衡数据集上，BERT 比 FastText 高出 +2.31 F/。

不过，BERT 的计算成本高于 FastText。要对 1,24194 个样本进行分类，BERT 在 Nividia 2080 Ti GPU 上需要 11 分钟，而 FastText 在 8 核英特尔 CPU 只需 5 秒钟就能对相同的数据集进行分类。

表 6.1 根据平衡和非平衡训练的 BERT 的 F1 *微*数值
数据集。

数据集	平衡	不平衡
惊吓	0.9409	0.9436
GermEval-2017	0.7727	0.7885
假日检查	0.9552	0.9775

SB10k	0.6930	0.6720
电影发行	0.9062	0.9219
PotTS	0.6423	0.6502
情感	0.9652	0.9621
莱比锡-维基百科	0.9983	0.9981
复式	0.9636	0.9744

https://github.com/huggingface/transformers

消融术

机器学习模型的一个重要问题是：训练好的模型能否泛化并成功地将所学知识应用到新的、未见过的数据中？为了接近这个问题，我们在组合数据集中删除了一个数据集，然后重新训练所有模型。用测试集和省略的数据集对所得到的模型进行评估。本研究选择了分数数据集。[Sän+J 6]指出，该数据集包含以口语撰写的简短应用程序评论，与其他评论文本相比，更类似于 Twitter 会话。通过省略该数据集，可以检验模型是否能够从两个领域学习信息并将其应用于该数据集。表格

6.J 2 比较了 BERT 和 FastText 在此任务中的训练结果。虽然两个模型的 F 值在未见分数集上都有所下降，但两个模型都从组合数据集中学习到了可以应用于未见分数应用程序评级的特征。不过，BERT 的 Fi 值为 0.80，FastText 的 F/ 值 0.73 高出 9.4%。

表 6.12：Fi<.-FastText 和 BERT 的模型值，这两个模型是在不带*分数*的平衡数据集上训练的。最后一行是有*评分*测试数据的模型值。最后一列显示了 BERT 与 FastText 模型之间的百分比差异。

数据集	快速文本	伯特	提高百分比
GermEval-20J7	0.6843	0.7727	+J2.9
假日检查	0.9275	0.9542	+2.9
SBJOk	0.6626	0.6840	+3.2
电影发行	0.8414	0.9164	+8.9
PotTS	0.5816	0.6667	+14.6
情感	0.9916	0.9832	-0.8
莱比锡-维基百科	0.9867	0.9985	+1.2
复式	0.9415	0.9649	+2.5
惊吓	0.7338	0.8039	+9.4

6.4.3 结果

为德语开发了一个通用情感分类模型。为此，将专家手动标注的各种数据集与用户标注的大型数据集结合起来。由此产生的数据集包含不同的领域，

涵盖不同的语言风格。通过这种方法，创建最大的公开可用的德语情感分类语料库，其中包含 530 万个文本。此外，还在该数据集上比较了两种不同分类模型的性能。两个模型都显示出良好的效果，FastText 的 1-WeFtVO 为 0.94，BERT 为 0.96。此外，还测试了这两种模型在以前未曾见过的领域的数据上的表现。在这项测试中，BERG 的表现比 FastText 高出约 9%。这表明 BERG 更适合对未见过的领域的数据进行分类。

创建的模型和数据集具有很高的实用性，可VUI 之外的各种用途。在 2020 年 1 月至 2024 年 2 月期间，基于 BERT 的模型被下载超过 470 万次[6]。

6.4 基于文本的情感分析

6https://huggingface.co/oliverguhr/german-sentiment-bert

6.4 基于文本的情感分析

7 对话管理

7.1 从意图到行动

对话管理（DM）的基本任务是根据用户的意图适当的操作。在实现数字助理（DA）的情况下，NLP 组件从用户的陈述中提取意图。

然而，在合成孔径雷达中还必须集成更多的信息或信号。信号可以是由传感器或软件模块传输的信息。例如，当机器人与物体发生碰撞时，保险杠会发出直接的传感器信号。来自软件模块的信号的一个例子是，当人员探测系统报告机器人前方有一个已知的人时。

选择机器人的适当反应既可以基于规则，也可以由学习算法决定。这两种方法的具体优缺点和实施方案将在第 7.2 节中介绍。

大型语言模型（LLM）的使用为提高对话和互动的质量提供了新的机遇。因此，虚拟用户界面可以将世界知识融入语句中。此外，这些模型还能将信息以文本的形式纳入到任务中。例如，在 MAKS 疗法中，可以使用 LLM 对报纸评论中的长篇新闻文章进行总结。

MAKS疗法参与者的信息也可用于提出具体问题。如果机器人朗读了有关森佩尔歌剧院的新闻，那么就可以提出与参与者相关问题："Muller 夫人，您曾在森佩尔歌剧院工作过，您参加过哪些演出？下一节将详细介绍使用生成式人工智能时出现的应用场景和具体风险。

最后，生成的语句必须转换成音频信号。为此可所谓的 TTS 系统。DiQ 框架条件和合适系统的选择将在第 7.4 节中说明。

7.2 对话管理程序

作为马尔科夫链的对话

算法或学习方法用于控制对话。对话建模的一个著名模型是罗伊、皮诺和特伦[RPT00]所描述部分可观测马尔可夫决策过程（POMD）。这种方法的一个优点是，不可靠的语音识别系统可以补偿转录错误。另一方面，创建必要的对话模型一项挑战。各个对话步骤之间的所有状态转换都必须建立模型，并分配转换概率。这些转换概率必须由对话设计者估算，这被视为潜在的错误来源[Luc+J 3b]。另外，也可以从现有的对话中学习转换概率[FHBJ 4]，在实践中，由于还没有合适的对话系统来收集数据，因此往往缺乏此类数据。

控制对话的行为树

行为树（BT）广泛应用于计算机游戏[LBCJ 0]。基于这一应用领域，行为树正越来越多地应用于机器人和人工智能领域[CÖJ 8; Colt 7]。[CÖJ 8; Colt 7]。机器人操作系统（ROS）也使用 BT 进行规划 [SF1 7]。

行为树是一种分层数据结构，用于代理的行为。该结构由以树形结构排列的节点组成。这种排列方式可将复杂的行为分解为模块化单元。模块化被视为这种方法的主要优点。/.安德鲁-巴格韦尔*等人*[A+12]对此表述如下：*其主要优势在于，单个行为可以很容易地在另一个更高层次行为的上下文中重复使用，而不需要 CO S|08Ci/f ROW t/E'f FE'l0tC CO SUbSE'quent behaviors*。此外，BT 的功能与第 4.3.J 章中描述的概念一致，即单个交互被分解成可用于不同交互场景的模块（技能）。严格的 BT 层次结构会使平行行动或决策难以建模。此外，与神经网络等学习方法不同，行为树无法提供独立适应新情况的可能性。

用于对话管理的神经网络

神经网络是对话管理领域一个活跃的研究课题。这些方法通常基于序列到序列模型，这些模型起源于机器翻译。这些模型将输入文本（如用户的陈述）映射到输出文本（即系统的响应）。混合代码网络[WAZ1 7]就是一个例子，它还能将编程功能整合到对话中。

通过使用迁移学习和 Transformer 架构，这种方法得到了进一步发展。这些模型的特点是

这种方法的例子包括 DialogGPT [Zha+20]，它是一种基于 GPT-2 的模型，使用对话数据进行训练；Blenderbot [Ral+20]，它是一种用于对话的特殊架构。这种方法的例子包括 DialogGPT [Zha+20]，这是一个基于 GPT-2 的模型，已通过对话数据进行了训练；Blenderbot [Ral+20]，这是一个用于对话的特殊架构；以及 Godel [Pen+22]，这是一个可以映射目标对话过程的模型。然而，所有这些程序都只适用于英语。

多种方法 在对话管理领域，我们依靠大型语言模型

(LLMs) 是根据用户反馈通过强化学习 (RL) 训练出来的。VQFfOlgtQ 这种方法的第一个模型是 ChatGPT [Ouy+22]。该模型可通过 API 以商业方式获得。这种方法后来被复制，现在已经有了可以在专有硬件上运行的模型。其中包括可以处理德语文本的 Llama 2 [Tau+23]，以及 Falcon 180B[1]。

这三种模式都能德语文本。另一种

LLLV 方法的一个决定性优势是，模型的行为可以通过提示来控制。在许多应用中，这样就用于训练模型的特定数据集，这在开发过程中是一个相当大的优势。

在对话管理方法方面，神经网络具有一定的优缺点。灵活处理 NUtZer 请求被认为是主要优势之一。对话设计者没有预料到的问题可以得到有效的回答。此外，由于对话流程是由模型学习的，因此无需像基于 BT 和 POMDs 的方法那样明确定义，从而节省了对话设计的时间。

不过，这种方法也缺点。例如，需要大量的训练数据，而且不能直接映射多阶段流程（如 BT）。虽然 LLM 可以使用提示根据特定用例进行定制，但它们也受益特定领域的训练数据。，响应是在运行时生成的，这意味着在系统开发过程中保证特定的响应行为。因此，可能会生成不合适或不理想的语句。我们还注意到，功能强大的 LLM 超过了大多数 SAR 目前的处理能力，因此无法其硬件上运行。

一般来说，基于 LLM 的方法使对话管理能够非常灵活地响应用户请求。然而，响应行为只能在有限的范围内进行控制或预测。因此，应通过系统生成的响应对 lnsensöen 应用计算广泛测试，以排除不良行为。这一过程被

称为对齐，是当前研究的主题[Wan+23b]。

7.3 模块化对话管理系统

上一节介绍了用户与系统交互的各种方法。

特点。作为一种首选方法，Behavor Trees（Behavor es）被认为是一种可持续的树种。

参与技术研究的研究人员已经公布了一个模型。模型本身可通过以下网站获取 https://huggingface.co/tiiuae/falcon-J80B-chat

确定了实施方案。这一决定基于几个因素。

BT 的结构适合于用单独的、可重复使用的模块来表示复杂的交互。这对于 4.3.J 节所述的技能映射尤其有利。BT 的树形结构可以简化对话的描述，而且不需要对转换概率进行估计。与其他方法相比，实施 BT 不需要收集训练数据。

对话管理器行为可以用 BT 来解释，因为树中的所有决定都是基于固定的规则。在资源有限的系统上高效执行 BT 也被认为是一种优势。此外，BT 不特定的输入模式，这增加了其在多模式交互场景中的适用性。

如有必要，还可以整合功能强大的 LLM，将两种方法的优势结合起来。基于这些因素，我们选择了 BT 作为实施对话管理的基础。

行为树中的控制流

行为树 (BT) 被定义为一棵有向树。这棵树由三种不同类型的节点组成：根节点、控制流节点和执行节点。

根节点被描述为一个没有父节点的节点，并且正好有一个子节点。控制流节点根节点和执行节点之间的中间节点。它们有一个父节点和至少一个子节点。它们的主要功能是选择执行节点进行执行。相反，执行节点执行特定代码。它们只有一个父节点，没有子节点。

BT 的执行总是从根节点开始，可以按固定的时间间隔执行，可以由事件驱动执行。事件驱动执行被认为适用于对话管理（DM）的实施。行为树（BT）的主要任务是确定下一步应执行的操作。行为树（BT）会对不同类型的事件做出反应。这些事件包括

- 用户的声明，例如以语音命令的形式、
- 传感器印象，例如识别和问候用户或电池电量不足、
- 定时器事件，如过渡到时间控制的睡眠模式

BT 两种类型的控制流节点：选择节点和序列节点。这两种类型的控制流节点都从

左到右执行其子节点。执行节点执行完毕后，会返回一个状态，可以是 "成功 "或 "错误"。

如图 7.J ，序列节点会一个接一个地执行其所有子节点。如果所有子节点都处理成功，序列节点会返回

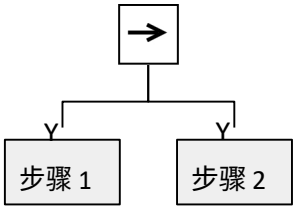

图 7.J：行为树中的序列节点用箭头表示。
灰色标出的子节点是执行节点。

返回*成功*状态。但是，如果子节点*错误*状态，序列的执行将被取消，序列节点也会返回*错误*状态。

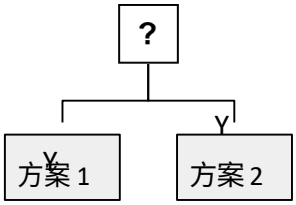

图 7.2：行为树中的选择节点用问号表示。灰色高亮显示的子节点是执行节点。

选择节点也称为后备节点，会执行其子节点，直到其中一个节点报告*成功*。因此，这些节点适用于替代行动策略或在特定条件下执行步骤。如图 7.2 所示，执行节点 "选项 2 "只有在 "选项 1 "报告*错误*状态时才会被激活。只有当子节点返回 *Eifolg* 状态时，该节点才会返回 *Eifolg* 状态。

符号如 [CÖ18, p.7 ff] 所述。为了简化表述，只采用了实现中也使用的节点类型。

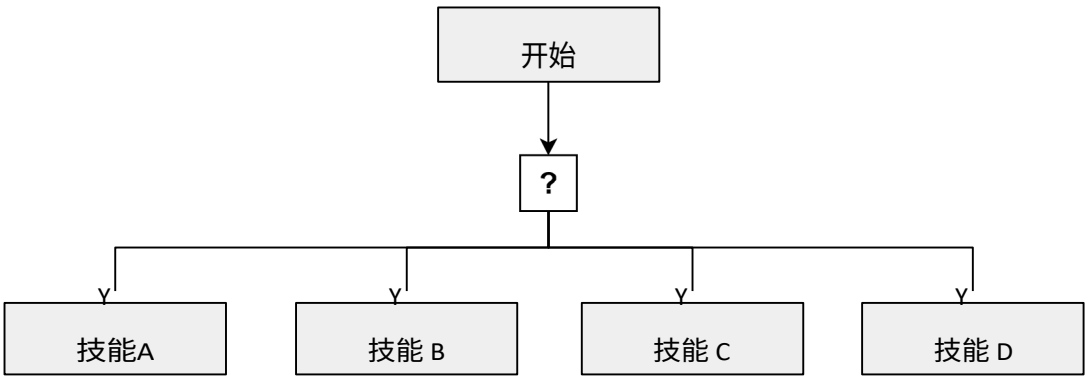

图 7.3：所有技能都是选择节点的子元素。只要第一个技能成功执行了事件，事件的处理就完成了。

图 7.3 选择要执行的技能。所有技能都作为选择节点的子节点排列。一旦第一个技能被成功执行，就不再处理触发执行树的事件的其他技能。为了简化开发，我们决定一个事件只一个技能处理。

如第 4.3.3 节所述，每个技能都会决定是否负责处理当前事件。为此，每个技能都会被 DM 自动转换为 BT 并添加到技能树中。

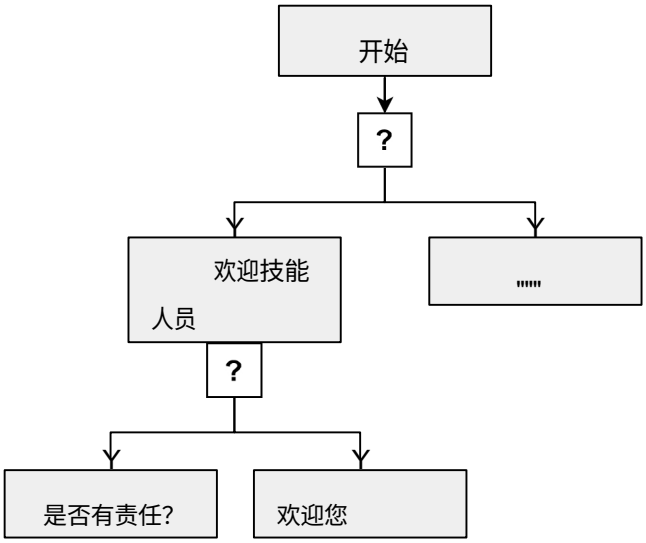

图 7.4：每个技能至少由一个选择节点和两个执行节点组成。

图 7.4 显示了一个具有 "欢迎人员 "技能的 BT 实例。 每个技能至少包括一个选择节点和两个执行节点。第一个执行节点由技能界面以 "*适合方法* "*的*形式指定。技能的 *is suitable* 方法决定是否执行该技能。如果该方法返回 /o/se 或状态 *Error*，则执行树中的下一个技能。

每个技能可以定义自己的子节点。这样就可以在一个技能中映射更复杂的流程。图 7.5 显示了 "欢迎人员 "技能中的流程，是图 7.4 的延续。

该子树从左到右依次执行。首先，系统会检查是否知道触发技能执行的人。在此过程中，会使用已经为机器人实现的人员识别功能。如果知道这个人的名字，就会执行序列中的下一步，并向这个人问好。如果不知道，左侧子树会返回错误信息。然后，顶部选择节点执行右侧子树，并在第一步中询问对方的姓名。如果对方报出姓名，技能就可以在下一步将姓名和照片保存到数据库中。

在顶层，对话管理使用序列来选择技能。每个技能都可以根据需要扩展 BT 并定义自己的流程。这种方法可以将 SAR 交互的复杂性划分给各个技能。

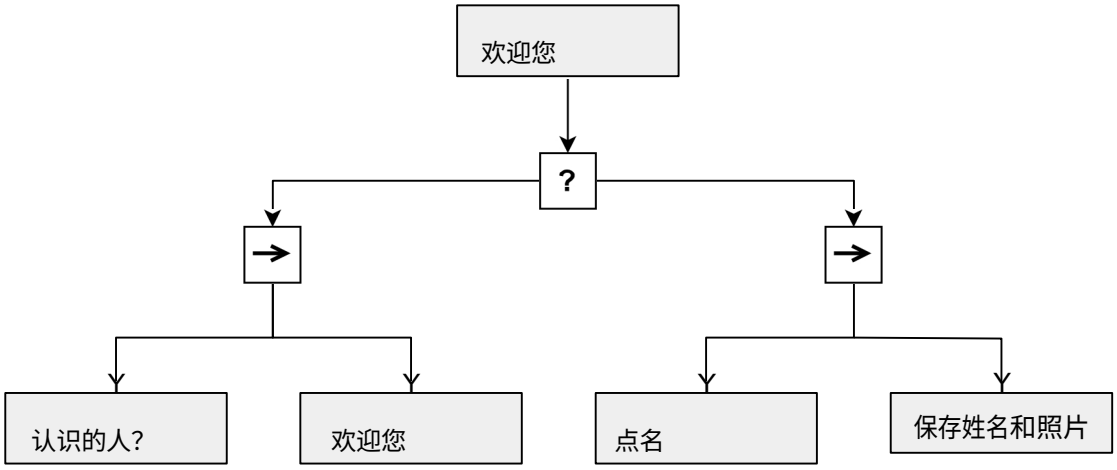

图 7.5：该 BT 一个多模式问候流程的示例。首先，系统会检查这个人是否认识并可以打招呼（树的左侧）。如果不认识，系统会询问对方的姓名。如果回答了这个问题，系统就会保存此人的姓名和照片，以便日后识别（树的侧）。

在开发技能时，只需考虑技能内流程。这就降低了开发人员复杂性。作为现有系统的进一步发展，运行时激活的 BT 可以。这将使系统开发和运行的人员能够以交互方式跟踪哪些技能处于活动状态，以及系统根据哪些信息做出了决定。

7.4 语音合成

一旦 DM 确定了要执行的操作，通常就会为用户生成口头响应。这项任务由语音合成完成，也称为文本到语音（TTS）。随着时间的推移，文本到语音的转换方法层出不穷，这一领域仍当前研究的主题。

通过使用基于深度学习的模型生成语言的质量得到了明显改善。与基于统计参数语音合成（SPSS）的模型相比，这些模型能够更好地映射人类语言的复杂性[Tay09; Nin+J 9]。

表 7 概述了与这项工作相关的出版物。值得注意的是，这些论文大多是 2023

年以前的。TTS 模型领域目前的发展包括通过使用深度神经网络提高语音质量，这一发展始于 [She+J 8]。多语言 TTS 模型的开发 [Duq+23; Pra+23] 和推理性能 [Ren+22] 也取得了进展。

以事实为基础客观地选择 TTS 模型一项挑战、

因为缺乏可比较的指标。TTS 模型最常用的指标是平均意见分（MOS）。这是一种评估感知媒体质量的指标。要确定 MOS，需要让一组测试对象按 5 分制对系统质量进行评分。然后将这些评分取平均值，得出主观 MOS 值。但需要注意的是，MOS 值容易被操纵和误解 [SWH16]。研究设计对获得的 MOS 值有很大影响，这使得该指标作为 TTS 模型质量的唯一比较工具并不可靠。

在实践中，还需要考虑更多的挑战。首先，复制结果要困难得多，因为许多作者既不公布模型，也不公布训练数据 [She+18]。其次，如表 7.1 所示，如果发表了模型，通常也是英语发表的。这进一步限制了模型的适用性和可比性。

在对工作组的治疗应用进行评估时，发现用户更喜欢尽可能自然的语音输出 [Bah+20]。本次评估的目的是找出一种既能提供高质量语音合成，又能在没有互联网连接的情况下在特区计算机上使用的模式。在选择和比较模型时考虑了各种因素。一般来说，只考虑作者提供了合成音频文件示例的出版物。这对了解模型的质量至关重要。另一个因素是模型的可用性，因为这对可能的实施必需的。我们也考虑了只有英语的模型，因为其结果有可能在德语版本中重现。最后，还记录了模型开发源代码的可用性。如果模型本身尚未出版或没有德文版，但却需要在德语世界中调整，这一点就尤为重要。

表 7.1：当前基于深度学习的 TTS 模型列表，包含所映射语言的详细信息以及模型和代码是否已发布。

模型	语言	型号 pub.	代码发布。
VaII-E [Wan+23a]	英语、中文、日语	没有	没有
YourTTS [Cas+22]	英语	是	是
SpeechT5 [Ao+22]	英语	是	是
SPEAR-TTS [Kha+23]	英语	没有	没有
自然语音 2 [她+23]	英语	没有	没有
FastSpeech 2 [Ren+22]	英语	是	是

FastPitch [Lan21]	英语、德语	是	没有
SeamlessM4T [Duq+23]	德语 + 35 种语言	是	是
彩信 TTS [Pra+23]	德语 +1 000 种语言	是	是
Tacotron 2 [She+18]	英语、德语	是 [2]	是
树皮 [3]	德语 + 12 个其他语言	是	是

在技术评估过程中，对表 7.1 中的最后五个模型进行了分析。作者提供德语 FastPitch[4] 模型无法生成可理解的语音。Meta Research、Seam-lessM4T 和 MMD TTS 的模型能够生成高质量的音频数据，但单词被改动或完全省略。来自 Coqui 的 Tacotron 2 模型是测试的五个模型中最老的一个，它生成的合成语音质量很好，但语调和语音节奏不是很自然。在合成数字、日期和时间时也问题。除语音外，Bark 模型还能生成清喉、笑声和咳嗽等辅助语音元素，但经常会产生一些假象，如突然发出高音调的声音。

所有五个模型的音频质量都被评为明显优于目前用于 MAKS 治疗的 Ivona TTS 模型(5)。不过，没有一个模型能够可靠地合成无误语音。鉴于目前在该领域发表的大量论文，我们可以期待进一步的进展。

由于观察到的错误模式，评估的模型都不适合实际使用。[6] 该模型主观上比 Ivona 目前使用的系统提供更好的语音质量，但语音合成需要互联网连接。与评估过的模型相比，微软的 TTS 模型可以无差错地合成文本。因此，该模型被第 8 章所述的评估。

如果不需要在系统运行时为用例生成新语句，也可以基于云的解决方案。为此，在启动 VUI 之前，数据库中的所有现有语句都会被合成并在缓存中。不过，这种方法不能用于 MAKS 治疗等用例，因为新语句必须在运行时生成。

https://catalog.ngc.nvidia.com/orgs/nvidia/teams/nemo/models/tts de fastpitch multispeaker 5

https://nextup.com/ivona/german.html

^https : //azure .m1c rosoft .com/en- deip roduct s/cogn1t1ve- se rv1ces/text- to- speech#features

[5] Coqui 的实现与模型 https : / /github .com/coqui-ai/TTS

[6]https : // hugg ing face .co/suno/bark

8 框架评估

8.1 结构和目标

语音用户界面（VUI）的设计目标是能够处理自然的日常德语，而用户学习特定的命令短语。为此，参与者被要求使用 VUI 任务。比较了有无事先培训的成功率。这项用户研究47 名不同人口背景的参与者。测试并不局限于特定的目标群体，因为虚拟用户界面的可用性应面向广泛而多样化的用户群体。

本节介绍了用户研究的结果，并测试设置进行了说明。研究结果以 "通过深度学习提高社会辅助机器人语音界面的可用性：一项德国案例研究 "为题提交给了 "2024 国际人机交互大会"，并被接受[Guh+24]。

8.2 测试设计和方法

本研究采用的是被试内设计。在每种条件下（训练和不训练），参与者都使用 VUI 完成任务。我们使用了两个不同的任务集：一个是 "机器人 "任务集，包括五个控制机器人有关的任务；另一个是 "AAL "任务集，包括五个与 AAL 平面有关的任务。为了将学习效应降至最低，训练条件的顺序（训练针对第一组还是第二组）和训练任务的选择（AAL 或机器人）都是随机的。训练部分包括五个示例任务和一个用于解决任务的示例语句。受试者在完成任务前接受了这一训练。在主要实验开始前，参与者需要完成两项入门任

务，以熟悉 VUI 的激活词（"Anna"）。激活交流的必要条件。测试结束后，参与者被要求完成人口统计学问卷和两份问卷UMUX-Lite [LUMJ 3] 和语音用户界面服务质量 (SUISQ) [PoI05; LUM 5]。

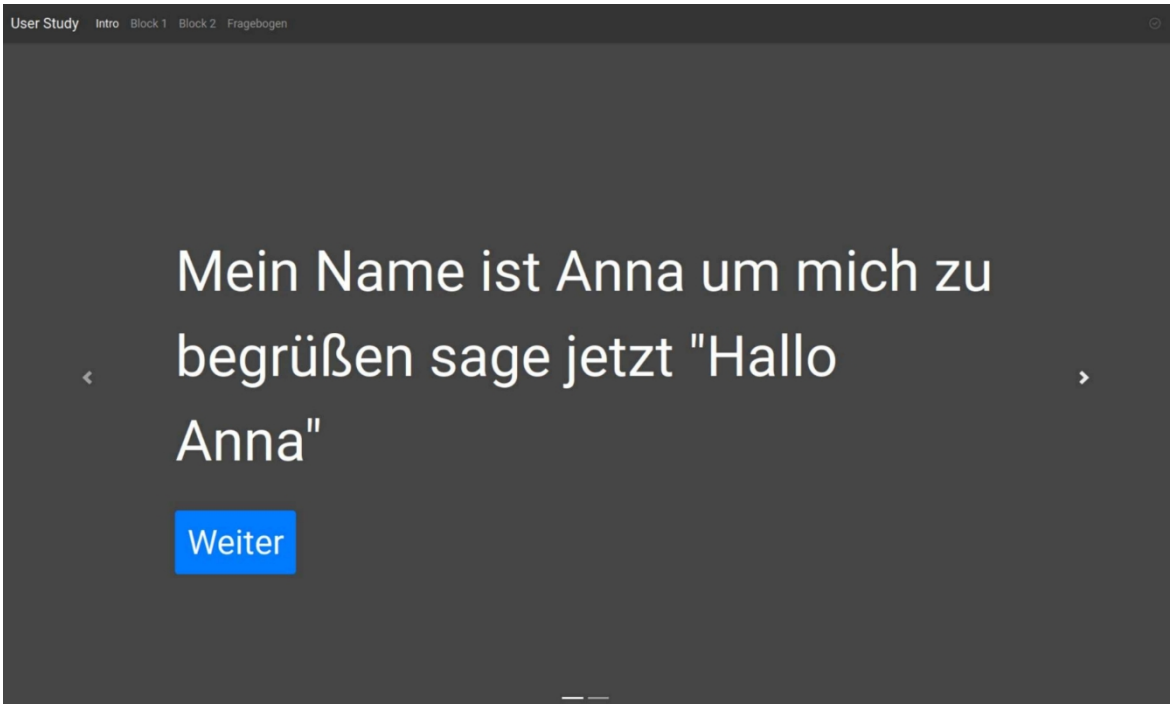

图 8.1：自动用户研究的用户界面示意图。界面上显示了任务描述 "我的名字是安娜，现在要向我问好，请说'你好，安娜'"和一个跳过测试的按钮。如果用户成功任务，软件就会自动下一个任务。

本研究根据两种情况下的失败率来检验特定方法的有效性：有培训和无培训。为此，我们对零假设（*）进行了如下检验：两组之间的错误率没有明显差异。因此，备择假设为（HAD.未接受培训组的错误率明显高于接受培训组。

开发了进行用户测试的软件，参与者完成测试程序。该软件的目的使测试具有可重复性和可比性，并自动记录测试遥测数据。测试装置包括一台笔记本电脑和一个外置麦克风。每次在一个房间内对一名参与者进行测试，这样参与者之间就无法相互观察。所有用户测试均以德语进行。

每次测试前都会对测试程序进行说明。解释说，受试者应按照屏幕上的说明，并输入激活词

"安娜 "来激活系统。如果虚拟用户界面理解了用户的命令，测试软件就会自动显示下一个任务。测试软件还解释说，如果系统正确理解用户的指令，用户可以重新措辞。如果受试者完成任务，他们可以选择使用屏幕

上的按钮跳过任务。图 8.1 显示了测试软件的用户界面。其中包括任务描述和跳过任务的按钮。

每次测试都从两个介绍性任务开始。在这一阶段，音量、屏幕亮度和任务说明的字体大小等设置都要根据用户的需要进行调整。

用户的下一步是解决两组任务。这些任务的制定方式不便于将其重新编排为命令。

可以实现。这些任务和场景都是机器人和人工耳蜗应用所要实现的功能。这是任务描述列表：

入门任务

1. 我叫安娜，要跟我打招呼，现在就说 "你好，安娜"。
2. 当你在句子中提到我的名字时，我总是会回答你。问我："安娜，是谁培养了你？"

机器人任务

1. 你想让安娜跟着你去另一个房间。请她这么做。
2. 您希望安娜一些，这样您就可以操作她的触摸屏。
   请他们这样做。
3. 您正在搬运一个大箱子，却发现安娜了您的去路。请她改变一下
4. 你要安娜离开房间，走廊。Bltte Six, ÖäS ZU tUD.
5. 您正站在博物馆的门厅里，想要乘坐电梯。请安娜帮助您。

AAL 任务

1. 您坐在客厅里，发现光线。请安娜改变一下。
2. 你刚睡醒，想百叶窗。求你了，安娜，这是为了
   你。
3. 你在厨房里，而厨房太冷了。让安娜换一下
4. 您时忘记关掉厨房里的收音机。请安娜帮您关掉。

5. 您坐在一把内置站立辅助装置扶手椅上，但您不知道该装置如何工作。问问安娜是否能帮到你。

在训练中，参与者会收到每项任务的陈述范例，要求他们读出来。为了与任务完全匹配，这些示例陈述都经过了缩写。